



Escuela Técnica Superior
de Ingeniería Informática

Grado en Matemáticas

Curso 2021-2022

Trabajo Fin de Grado

**ANÁLISIS Y PREDICCIÓN DE SERIES
TEMPORALES APLICADOS AL VIDEOJUEGO
*LEAGUE OF LEGENDS***

Autor: Manuel Martín Sierra

Tutora: Clara Simón de Blas

Cotutora: Ana Elizabeth García Sipols

Resumen

Actualmente el análisis estadístico ha supuesto una revolución en diversos sectores como el deporte o los videojuegos. Es por eso que muchos equipos competitivos han incluido en su plantilla especialistas en el análisis de datos. Este trabajo está dedicado a la recopilación y el estudio de tres estadísticas principales de las partidas ya disputadas del videojuego *League of Legends*. Este estudio nos permite la predicción de la evolución de las estadísticas con fines de ser utilizados en las próximas partidas y cambios de balance que se produzcan en el juego tanto a nivel amateur como competitivo.

Palabras clave:

- Python
- Web Scraping
- League Of Legends
- Estadística
- Análisis de datos
- Series temporales
- Análisis de conglomerados
- Predicciones

Índice de contenidos

Índice de tablas	V
Índice de figuras	VII
1. Introducción	1
1.1. Contexto y alcance	1
1.2. Fundamentos del juego	2
1.3. Interés del estudio	2
1.4. Metodologías	3
1.4.1. <i>WebScraping</i>	3
1.4.2. Series temporales	3
1.4.3. Análisis de conglomerados	4
1.4.4. Escalado multidimensional	4
2. Objetivos	6
2.1. Objetivos generales	6
2.2. Objetivos específicos	6
3. Adquisición y análisis de los datos	7
3.1. Arquitectura	7
3.2. Base de datos	8
3.3. Lenguaje de programación	8
3.4. Elección de los datos	8
3.5. Extracción de los datos	9
3.5.1. Almacenamiento de datos	9
3.6. Tratamiento de datos	11
3.6.1. Limpieza de los datos	11
3.6.2. Obtención de las series temporales	11
4. Técnicas de análisis de conglomerados	13
4.1. Elección de la distancia	13
4.1.1. Distancia euclídea	14
4.1.2. Distancia basada en la correlación	14

4.1.3.	Distancia de DTWARP	15
4.1.4.	Distancia de CORT	16
4.2.	Selección de la distancia	17
4.3.	Elección del encadenamiento	20
4.4.	Elección de los representantes	22
4.5.	Creación de grupos	23
5.	Técnicas de predicción	32
5.1.	Introducción a la predicción de series temporales	32
5.1.1.	Creación de los conjuntos de entrenamiento y de prueba	33
5.1.2.	Creación de variables auxiliares	33
5.1.3.	Procesamiento de las series temporales	34
5.1.4.	Definición de los estadísticos comparadores	34
5.2.	Modelo <i>SARIMA</i>	35
5.3.	Modelo <i>TBATS</i>	37
5.4.	Modelo de redes neuronales autorregresivas	41
5.5.	Modelo de los k vecinos más próximos	45
5.6.	Combinación de predicciones	49
6.	Resultados	56
6.1.	Resultados del conjunto de <i>winrate</i>	56
6.2.	Resultados del conjunto de <i>banrate</i>	56
7.	Conclusiones	59
8.	Mejoras y trabajos futuros	60
	Bibliografía	60

Índice de tablas

5.1. ECM y EAM obtenidos con el modelo <i>SARIMA</i> para el <i>winrate</i> .	37
5.2. ECM y EAM obtenidos con el modelo <i>SARIMA</i> para el <i>banrate</i> .	38
5.3. ECM y EAM obtenidos con el modelo <i>TBATS</i> para el <i>winrate</i> . .	41
5.4. ECM y EAM obtenidos con el modelo <i>TBATS</i> para el <i>banrate</i> . .	42
5.5. ECM y EAM obtenidos con el modelo <i>ARNN</i> para el <i>winrate</i> . .	42
5.6. ECM y EAM obtenidos con el modelo <i>ARNN</i> para el <i>banrate</i> . .	45
5.7. ECM y EAM obtenidos con el modelo <i>K-NN</i> Recursivo para el <i>winrate</i>	49
5.8. ECM y EAM obtenidos con el modelo <i>K-NN MIMO</i> para el <i>winrate</i>	49
5.9. ECM y EAM obtenidos con el modelo <i>K-NN</i> Recursivo para el <i>banrate</i>	50
5.10. ECM y EAM obtenidos con el modelo <i>K-NN MIMO</i> para el <i>banrate</i>	51
5.11. ECM y EAM obtenidos con el modelo combinación por Media Aritmética para el <i>winrate</i>	52
5.12. ECM y EAM obtenidos con el modelo combinación por Regresión lineal restringida para el <i>winrate</i>	54
5.13. ECM y EAM obtenidos con el modelo combinación por Media Aritmética para el <i>banrate</i>	54
5.14. ECM y EAM obtenidos con el modelo combinación por Regresión lineal restringida para el <i>banrate</i>	55
6.1. Tabla conjunta de todos los ECM y EAM para el <i>winrate</i> por modelo y grupo	58
6.2. Tabla conjunta de todos los ECM y EAM para el <i>banrate</i> por modelo y grupo	58

Índice de figuras

1.1. Nexo aliado	2
3.1. Arquitectura del sistema	8
3.2. Fichero con los datos completos de <i>bans</i>	10
3.3. Fichero con los datos de la tasa de victorias	12
3.4. Representación de la serie temporal de <i>Jinx</i> en R para el <i>winrate</i>	12
4.1. Escalado multidimensional distancia euclídea, basada en correlaciones, DTWARP y CORT aplicada al <i>winrate</i>	18
4.2. Escalado multidimensional distancia euclídea, basada en correlaciones, DTWARP y CORT aplicada al <i>banrate</i>	19
4.3. Encadenamiento de centroides aplicada a las cuatro distancias del conjunto de <i>winrate</i>	23
4.4. Creación de grupos de <i>winrate</i> con distancia <i>CORT</i> y encadenamiento de <i>Ward</i>	24
4.5. Grupos formados de <i>winrate</i> con distancia <i>CORT</i> y encadenamiento de <i>Ward</i>	25
4.6. Series de los representantes de los grupos para el <i>winrate</i>	27
4.7. Creación de grupos de <i>banrate</i> con distancia <i>CORT</i> y encadenamiento de <i>Ward</i>	29
4.8. Grupos formados de <i>banrate</i> con distancia <i>CORT</i> y encadenamiento de <i>Ward</i>	30
4.9. Series de los representantes de los grupos para el <i>banrate</i>	31
5.1. Comparación de el conjunto de datos de entrenamiento, verde y las predicciones por el modelo <i>SARIMA</i> , azul, para el <i>winrate</i>	36
5.2. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo <i>SARIMA</i> , azul y los datos de prueba, morado, para el <i>winrate</i>	37
5.3. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo <i>SARIMA</i> , azul y los datos de prueba, morado, para el <i>banrate</i>	38
5.4. Comparación de el conjunto de datos de entrenamiento, verde y las predicciones por el modelo <i>TBATS</i> , azul, para el <i>winrate</i>	39

5.5. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo <i>TBATS</i> , azul y los datos de prueba, morado, para el <i>winrate</i>	40
5.6. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo <i>TBATS</i> , azul y los datos de prueba, morado, para el <i>banrate</i>	41
5.7. Comparación de el conjunto de datos de entrenamiento, verde y las predicciones por el modelo <i>ARNN</i> , azul, para el <i>winrate</i>	43
5.8. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo <i>ARNN</i> , azul y los datos de prueba, morado, para el <i>winrate</i>	44
5.9. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo <i>ARNN</i> , azul y los datos de prueba, morado, para el <i>banrate</i>	45
5.10. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de k vecinos más próximos recursivo, azul y los datos de prueba, morado, para el <i>winrate</i>	47
5.11. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de k vecinos más próximos <i>MIMO</i> , azul y los datos de prueba, morado, para el <i>winrate</i>	48
5.12. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de k vecinos más próximos recursivo, azul y los datos de prueba, morado, para el <i>banrate</i>	48
5.13. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de k vecinos más próximos <i>MIMO</i> , azul y los datos de prueba, morado, para el <i>banrate</i>	50
5.14. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de combinación por la media aritmética, azul y los datos de prueba, morado, para el <i>winrate</i>	52
5.15. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de combinación por la Regresión lineal restringida, azul y los datos de prueba, morado, para el <i>winrate</i>	53
5.16. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de combinación por la media aritmética, azul y los datos de prueba, morado, para el <i>banrate</i>	53
5.17. Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de combinación por la Regresión lineal restringida, azul y los datos de prueba, morado, para el <i>banrate</i>	55
6.1. Comparación de todos los modelos para el <i>winrate</i>	57
6.2. Comparación de todos los modelos para el <i>banrate</i>	57

1

Introducción

1.1. Contexto y alcance

En la actual era de la digitalización y globalización, el buen uso de los datos es importante, porque supone una ventaja estratégica y competitiva para todas las empresas. Es la clave para crear y desarrollar estrategias exitosas para cualquier negocio.

El sector de los videojuegos no se queda atrás. Está en auge unas nuevas competiciones, conocidas en el ámbito popular como *eSports*. Estas competiciones se realizan entre equipos cualificados los cuales están respaldados por un amplio equipo de analistas de datos los cuales están encargados de realizar estadísticas sobre el equipo aliado, el enemigo o, incluso, un estudio detallado sobre el propio videojuego.

En los *eSports*, el videojuego dominante, sin lugar a dudas, es el *League of Legends*. Todo este proceso está respaldado por los grandes números que se consiguen gracias a las grandes competiciones regionales [1], a nivel nacional e internacional. Este juego se categoriza dentro del género de la estrategia, puesto que es la lucha donde diez personas, divididas entre dos equipos, se enfrentan para destruir antes la base del otro. En esta búsqueda por la victoria, se generan una serie de datos que pueden ser determinantes para explicar la victoria o pérdida de un equipo y que los analistas pueden utilizar para conseguir que su equipo logre la victoria en el próximo duelo.

Tanto las partidas competitivas como las casuales, arrojan mucha cantidad de datos que describen el *metagame* [2] actual y pueden ser analizados.



Figura 1.1: Nexo aliado

Fuente: <https://leagueoflegends.fandom.com>

1.2. Fundamentos del juego

Las partidas se desarrollan como un duelo entre dos equipos formados por cinco jugadores. Una vez formado los equipos, estos tienen un proceso de selección para seleccionar uno entre todos los campeones disponibles, sin repetirse en los dos equipos. Antes de elegir a su campeón, pueden eliminar un campeón para no lo pueda escoger ninguno de los equipos, este proceso es conocido por su palabra inglesa *ban*. Una vez concluido el proceso de selección, la partida empieza y una vez que se destruye la estructura principal, conocida como nexos (1.1), o se rinda uno de los dos equipos, se termina la partida con un equipo ganador.

1.3. Interés del estudio

Riot Games, la empresa creadora del videojuego, lanzó a finales del año 2013 [3] una *API* para poder extraer datos sobre partidas. Esto provocó que surgieran muchas páginas dedicadas a ofrecer estadísticas individuales sobre jugadores, así como ofrecen estadísticas sobre los mejores campeones por posición sobre la versión actual del juego. Además, la página <https://www.leagueofgraphs.com> ofrece un amplio servicio de estadísticas sobre cada campeón por individual a

lo largo del tiempo. Estas páginas se han vuelto una parte fundamental para jugadores que quieren escalar en la liga individual del juego y las utilizan para informarse de cuáles son los mejores campeones para utilizar, qué objetos se tiene que comprar y qué habilidades potenciarse. En esta página se han creado una serie de gráficos que muestran estadísticas sobre campeones en el tiempo sobre algunas variables, que pueden ser utilizadas para evaluar el futuro del personaje para ganar ventaja a la hora de seleccionar o eliminar campeones en el proceso de selección.

1.4. Metodologías

1.4.1. *WebScraping*

El *WebScraping*, también conocido como raspado web, es una técnica empleada por programas de software para extraer información de sitios web. Estos programas suelen simular la navegación humana en la *World Wide Web*, ya sea mediante el protocolo *HTTP* o mediante la inclusión de un navegador en una aplicación. Aunque relacionado con la indexación web, el *WebScraping* se enfoca en la transformación de datos no estructurados en información estructurada que pueda ser almacenada y analizada en una base de datos central, hoja de cálculo u otro medio de almacenamiento. Algunas de las aplicaciones del *WebScraping* incluyen la comparación de precios en tiendas, la monitorización de datos climáticos y la integración de información en sitios web. Asimismo, puede ser utilizado para obtener información relevante de una página web a través de los *rich snippets*. En la actualidad, el *WebScraping* se ha convertido en una técnica muy popular en el sector de posicionamiento web debido a su capacidad para generar grandes cantidades de datos de calidad.^[4]

1.4.2. Series temporales

Se trata del resultado de observar el mismo fenómeno en intervalos regulares de tiempo diarios, mensuales, anuales, horarios. Una serie temporal se define como una colección de observaciones de una variable recogidas secuencialmente en el tiempo. Estas observaciones se suelen recoger en instantes de tiempo equiespaciados. Si los datos se recogen en instantes temporales de forma continua, se debe o bien digitalizar la serie, es decir, recoger sólo los valores en instantes de tiempo equiespaciados, o bien acumular los valores sobre intervalos de tiempo. La característica fundamental de las series temporales es que las observaciones sucesivas no son independientes entre sí, y el análisis debe llevarse a cabo teniendo en cuenta el orden temporal de las observaciones. Los métodos estadísticos basados en la independencia de las observaciones no son válidos para el análisis de series

temporales porque las observaciones en un instante de tiempo dependen de los valores de la serie en el pasado.

Por ello, una serie temporal es una secuencia de datos observados en el tiempo, que se recopilan a intervalos regulares o irregulares. Formalmente, una serie temporal se puede definir como una función matemática $X(t)$ que asigna un valor numérico X_t a cada instante de tiempo t en un intervalo de tiempo $[0, T]$:

$$X(t) = X_1, X_2, \dots, X_t, \dots, X_T$$

Donde X_t es el valor observado en el instante de tiempo t , y T es la longitud del intervalo de tiempo donde se han realizado las mediciones de la característica del estudio. Se asume que $X(t)$ es una realización de un proceso estocástico, es decir, una serie de variables aleatorias que evolucionan a lo largo del tiempo. El análisis de series temporales implica la identificación de patrones y tendencias en los datos a lo largo del tiempo, así como la predicción de valores futuros basados en la información histórica.

1.4.3. Análisis de conglomerados

Es la técnica que pretende detectar la división natural de los objetos, agrupando observaciones similares en subconjuntos homogéneos. Estas subclases revelar patrones asociados con el fenómeno que se estudia.

Los algoritmos de agrupación pueden utilizarse para encontrar agrupaciones naturales si hay muchos casos y no son claras. A parte, pueden servir en el pre procesamiento de datos para clasificar grupos homogéneos en los que se puedan construir modelos supervisados. Y por último, para detectar anomalías. Al segmentar los datos en clusters, algunos casos podrían no encajar en ninguno. En estos casos hay excepciones o valores atípicos.

1.4.4. Escalado multidimensional

El escalado multidimensional es una técnica utilizada principalmente en estadística y análisis de datos para representar información en un espacio dimensional reducido. Esta técnica se basa en la idea de que los objetos que se parecen en múltiples aspectos probablemente sean similares en general. El escalado multidimensional permite visualizar y analizar datos en múltiples dimensiones, lo que permite identificar patrones y tendencias en grandes conjuntos de datos. Además, esta técnica es muy útil para reducir la complejidad de los datos sin perder información importante, lo que puede facilitar su análisis y comprensión.

Existen varios tipos de escalado multidimensional, pero todos tienen en común la idea de transformar los datos originales en un espacio de menor dimensión, manteniendo ciertas propiedades como las relaciones de proximidad entre los objetos. Esto se logra mediante la construcción de una matriz de distancia o similitud que representa la relación entre los objetos en múltiples dimensiones. Luego, se utiliza un algoritmo de escalado multidimensional para proyectar los datos en un espacio de menor dimensión, preservando en la medida de lo posible las relaciones de proximidad entre los objetos. Es una técnica poderosa para analizar y visualizar grandes conjuntos de datos en múltiples dimensiones, permitiendo identificar patrones y relaciones entre los objetos de manera más clara y eficiente.

2

Objetivos

2.1. Objetivos generales

Con este estudio, se pretende desarrollar un análisis utilizando series temporales de cómo van a evolucionar los datos que se han extraído sobre campeones y compararlos con los resultados reales.

2.2. Objetivos específicos

- Extraer el mejor modelo para cada serie.
- Extraer datos temporales de la mayoría de campeones.
- Extraer datos de todas las versiones posibles de los campeones.
- Clasificar los datos en grupos.
- Predecir el comportamiento de estos datos en el futuro.
- Comparar los resultados con la realidad. posibles mejoras en el estudio.

3

Adquisición y análisis de los datos

Este capítulo se relata la causa de la elección de los datos que se han extraído de la página, los métodos utilizados y la limpieza de datos.

3.1. Arquitectura

La arquitectura (3.1) del sistema es muy sencilla:

- Mediante la técnica de extracción de datos *Webscraping*, se realiza la extracción de datos de la página web <https://www.leagueofgraphs.com>.
- La información individual obtenida es almacenada en un archivo de formato *csv* para cada personaje según se va extrayendo la información de cada campeón.
- Una vez obtenido el conjunto de datos completo, se procede a realizar la limpieza y tratamiento de datos, es decir, la comprobación de si los datos extraídos son correctos y se encuentra algún *outlier*.
- El *excel* final se emplea para la visualización, el estudio de los datos y el modelado final.
- Este *excel* final es la base de datos que se utilizará en el programa *R* para la limpieza y utilización de los datos.




Figura 3.1: Arquitectura del sistema
Fuente: Elaboración propia

3.2. Base de datos

Puesto que las tablas a analizar no resultan muy complejas en cuanto a la organización de los datos, se ha decidido no emplear ningún tipo de base de datos, siendo suficiente el almacenamiento de datos en formato *csv* y su visualización con Microsoft Excel.

3.3. Lenguaje de programación

El lenguaje de programación empleado ha sido *Python* para la extracción de los datos de la página web ya que se han empleado las librerías *Selenium*, para el manejo dinámico de la web; y *BeatifulSoup*, para la búsqueda de los elementos *HTML* en la técnica de *Webscrapping*. Para la lectura y escritura de los datos se ha utilizado la biblioteca de *CSV* aparte de otras bibliotecas de visualización y manejo de *datasheet* como son *pandas* o *plot*. Por otro lado, el lenguaje utilizado para el manejo de series temporales es el programa *R*.

3.4. Elección de los datos

Una vez analizado el conjunto de datos ofrecidos por versión, solo encontramos datos sobre los campeones en el tiempo de las siguientes tres variables:

- Porcentaje de victorias: este ratio divide las partidas en las que el campeón

ha ganado entre el total de partidas en las cuales se ha seleccionado.

- Porcentaje de *bans*: este ratio divide las partidas en las que el campeón se ha baneado entre el total de partidas.

Se seleccionó esta página para la extracción por ser la única que cuenta con gráficos que incluyen datos sobre su porcentaje de victorias y su porcentaje de *ban* en el tiempo. Estos datos son extraíbles y van desde que se creó la *API* de *Riot Games* hasta la actualidad.

3.5. Extracción de los datos

Para la extracción de datos se ha utilizado la técnica de *WebScraping*. El proceso de recopilación y depuración de los datos es imprescindible en el análisis de datos, y esta ocupa un alto porcentaje del tiempo del estudio. Los datos se han extraído como se relatan en el apartado 3.5[5] del documento citado.

3.5.1. Almacenamiento de datos

Para el almacenamiento de datos, se ha decidido el uso del formato *CSV*, ya que es bastante común este tipo de almacenamiento de datos, pues es fácilmente manejable por el lenguaje *Python*. Con la librería *CSV*, se crean dos nuevos ficheros tipo *.csv* que corresponden con las dos características a analizar (Tasa de victorias y Tasa de *bans*). Para ello, en cada fichero se ha escrito al principio la fecha ordenada de más reciente a más antigua debido a que el juego continúa lanzando nuevos personajes y no existen datos anteriores de estos. Una vez extraídos los datos de las dos características a la vez, se abren los dos ficheros, se escriben los datos en la columna con el nombre del personaje al principio y se cierra el fichero para evitar errores. Al almacenarlos de esta forma es más manejable con el lenguaje de *R* al convertir fácilmente sus tablas por *datasheets* y poder exportar todos los datos de cada campeón al mismo tiempo. Finalmente se han generado dos documentos de *CSV* por cada característica con toda la información de los campeones desde el 11-03-2014 hasta la fecha del parche, 26-04-2022. La imagen (3.2) muestra un ejemplo de cómo se han almacenado los datos en el fichero y se puede comprobar que *Akshan* ha sido lanzado recientemente y no tiene datos anteriores a agosto de 2021. Esto ha permitido bastante la rápida limpieza de datos.

	A	B	C	D	E	F	G
1	date	aatrox	ahri	akali	akshan	alistar	amumu
2	2022-04-26	0,200912	4,332105	0,395787	5,427132	0,960639	1,443748
3	2022-04-11	0,187394	2,729242	0,260379	5,013168	2,623579	0,822165
4	2022-03-27	0,197968	2,79655	0,308876	4,731475	3,133248	0,872611
5	2022-03-12	0,269681	3,053896	0,325745	4,216067	3,914222	0,841532
6	2022-02-25	0,254741	3,940292	0,307874	4,646833	2,923446	0,574285
7	2022-02-10	0,250342	5,089293	0,324628	4,461081	1,414069	0,477582
8	2022-01-26	0,203859	3,365529	0,197694	3,654953	0,677186	0,343602
9	2022-01-12	0,210241	2,326946	0,182699	3,721449	0,60035	0,273523
10	2021-12-29	0,217665	2,204983	0,209403	4,174728	0,459997	0,346565
11	2021-12-14	0,160506	1,145733	0,149297	4,086684	0,588611	0,228878
12	2021-11-29	0,167234	0,919129	0,158675	4,001442	0,461455	0,235708
13	2021-11-15	0,239196	0,742548	0,229688	3,953253	0,436688	0,207105
14	2021-11-01	0,206024	0,792628	0,20068	3,936815	0,583394	0,261835
15	2021-10-18	0,23697	1,081058	0,192757	4,104538	0,57526	0,292506
16	2021-10-03	0,219296	1,124129	0,187878	4,134517	1,832696	0,285588
17	2021-09-19	0,113363	0,354258	0,113363	4,073914	44,05286	0,113363
18	2021-09-05	0	0	5,286344	4,078932	17,503	0
19	2021-08-21	0,1712	1,100527	1,374321	4,254676	18,28132	0,694241
20	2021-08-06	0,19352	0,991395	0,686045	4,33698	18,34806	0,781219
21	2021-07-23	0,178945	1,010007	0,429812		17,79082	0,843795
22	2021-07-08	0,227941	0,917464	0,389637		19,15343	0,807411
23	2021-06-23	0,198442	0,773382	0,373099		14,16554	0,718334

Figura 3.2: Fichero con los datos completos de *bans*
Fuente: propia

3.6. Tratamiento de datos

La depuración y tratamiento de datos es vital para garantizar una alta integridad de los datos.

3.6.1. Limpieza de los datos

Una vez obtenidos todos los datos necesarios, se procede a comprobar si existen algunos datos que alteren el resultado final. En este caso se puede comprobar que los datos en sí son precisos y no existe ningún outlier. Por otra parte, se requiere una amplia existencia de datos de personajes. El juego está en activo, y se lanzan personajes con una regularidad de tres meses. Por otra parte, teniendo en cuenta de que la *API*, no fue lanzada hasta finales de 2013, se obtuvieron datos bastante irregulares de los personajes que los caracterizamos en dos bloques:

- Campeones anteriores a 2013: de los que tenemos todos los datos hasta la actualidad.
- Campeones posteriores a 2013: de los que tenemos datos a partir del día en que fueron lanzados hasta la actualidad.

Debido a la irregularidad de los datos, se ha tomado como criba la de mantener los personajes con una antigüedad de cinco años. Se han limpiado todos los datos anteriores a 29-01-2017. Se ha elegido esta fecha debido a que el inicio de la temporada 7 fue el 30-01-2017 [6], y cuando empieza la temporada, las partidas son más competitivas y los datos son más reales. Una vez finalizada una temporada, se incluyen cambios muy drásticos en el juego, lo que producen dos meses de datos más libres que no se ajustan tanto a la realidad. Al utilizar datos desde la temporada 7 en adelante, se promueve una mayor calidad de los datos ya que el juego está bastante maduro y se evitan datos exagerados de las fases tempranas del juego. Por ello se han eliminado todos los datos anteriores a esta fecha incluyendo a los campeones lanzados posteriormente, pasando de un conjunto inicial de 159 personajes a 134 personajes.

3.6.2. Obtención de las series temporales

Tras haber recopilado y tratado todos los datos necesarios para el análisis, el siguiente paso es definir el programa informático o lenguaje de programación que se vaya a usar para el resto del análisis. Se ha elegido R gracias a la cantidad de librerías sobre series temporales que contiene así como el uso de las funciones de la clase *ts*.

Con la información extraída de la página web y almacenada en los tres ficheros de *Excel* ordenados por estadística, para obtener las series temporales a las que

1	date	aatrox	ahri	akali	alistar	amumu	anivia
2	2022-04-26	50,58	53,26	51,07	49,06	51,83	53,02
3	2022-04-11	51,63	53,29	51,83	49,07	51,72	54,36
4	2022-03-27	50,91	53,04	51,9	48,69	51,84	50,76
5	2022-03-12	52,7	54,56	50,54	48,81	52,42	52,78
6	2022-02-25	51,52	54,43	49,93	49,39	51,66	53,13
7	2022-02-10	51,78	54,43	48,96	49,01	52,64	52,81
8	2022-01-26	51,26	53,85	49,74	48,75	53,18	53,05
9	2022-01-12	51,28	53,81	49,84	48,83	52,99	52,67
10	2021-12-29	51,64	53,34	49	48,89	52,59	52,91
11	2021-12-14	52,45	53,31	50,38	49,14	52,66	51,99
12	2021-11-29	52,92	53,38	51,65	50,22	52,53	54,17
13	2021-11-15	51,52	53,44	47,32	50,01	52,56	55,01
14	2021-11-01	53,05	54,2	49,75	49,96	52,7	52,11

Figura 3.3: Fichero con los datos de la tasa de victorias
Fuente: propia



Figura 3.4: Representación de la serie temporal de *Jinx* en R para el *winrate*
Fuente: propia

aplicar las técnicas de análisis, se recurre al mismo programa, por su facilidad en el manejo y, para las técnicas de series temporales, al lenguaje de programación R. Se puede observar en la figura (3.3) un ejemplo de los datos ordenados por fecha que están guardados en cada fichero de *Excel*.

En cuanto a la granularidad de la serie temporal, se escogen datos cada dos semanas debido a que esta es la frecuencia con la que se lanza un nuevo parche del juego. Como consecuencia de esta granularidad, la repetición anual de los momentos temporales es de 26.

Para etiquetar los momentos temporales, se generan las etiquetas temporales que van del 1 al 26. De esta forma, la serie temporal de cada campeón va desde la segunda bisemana de enero de 2017 (Bisemana 2 de 2017) hasta la séptima bisemana de marzo de 2022 (Bisemana 7 de 2022). Ejemplo de serie temporal introducidas del campeón *Jinx* (3.4).

Con todas estas pautas, conseguimos 134 series temporales bisemanales desde la bisemana 2 del año 2017 hasta la bisemana 2 del año 2022 para dos variables distintas que son el porcentaje de victorias y el porcentaje de *ban*.

4

Técnicas de análisis de conglomerados

En el mundo del análisis de datos se caracteriza por haber una gran cantidad de unidades estadísticas disponibles para analizar como observaciones o instancias, que se corresponden con las filas y por la cantidad de variables medidas para cada una de estas unidades, que se corresponden con las columnas. No todas estas variables son igual de relevantes en el estudio, por tanto con el análisis de conglomerados se reduce la dimensionalidad para ayudar a simplificar y hacer más manejables los problemas a estudiar. Esta sección consta de cinco secciones que relatan la definición y selección de la distancia, del encadenamiento y del representante para la creación de los grupos.

4.1. Elección de la distancia

Para la aplicación de el análisis de conglomerados a las series temporales, se necesita estudiar las distancias que se pueden aplicar entre ellas. Para esto se han aplicado las técnicas definidas en [7]. Estas distancias se calculan sobre los datos restantes después de la limpieza de dato. Las series estandarizan restando la media y dividiendo entre la desviación para que la diferencia entre escalas de las unidades no distorsione los valores.

Se ha decidido utilizar cuatro tipos de distancias:

4.1.1. Distancia euclídea

La distancia euclídea es una medida de la distancia entre dos puntos en un espacio euclídeo de cualquier número de dimensiones. Esta distancia se define como la longitud del segmento de línea recta que conecta los dos puntos en el espacio. Esta distancia, es un caso concreto de las distancias de Minkowski cuando $q=2$. Sean $x_t = (x_1, \dots, x_t, \dots, x_n)$ y $y_t = (y_1, \dots, y_t, \dots, y_n)$ las series temporales se define la distancia euclídea entre ellas como:

$$d_{\text{euclídea}}(\mathbf{x}_t, \mathbf{y}_t) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (4.1)$$

4.1.2. Distancia basada en la correlación

La distancia basada en la correlación es una medida de la similitud entre dos conjuntos de datos. Esta medida se utiliza para determinar la similitud entre dos series de tiempo o entre dos variables numéricas.

La distancia basada en la correlación se define como la distancia euclídea entre los vectores de correlación de dos conjuntos de datos. Dadas dos series temporales $x_t = (x_1, \dots, x_t, \dots, x_n)$ y $y_t = (y_1, \dots, y_t, \dots, y_n)$, cuyas medias son $\bar{x}$ e $\bar{y}$, primero se calcula la correlación entre series con la fórmula:

$$\rho(x_t, y_t) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (4.2)$$

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^n (\rho_i(\mathbf{x}, \mathbf{y}) - \bar{\rho}(\mathbf{x}, \mathbf{y}))^2}$$

donde $\bar{\rho}(\mathbf{x}, \mathbf{y})$ es la correlación entre los vectores $\mathbf{x}_t$ y $\mathbf{y}_t$. Esta medida de distancia se basa en la idea de que dos conjuntos de datos son más similares si sus correlaciones son similares.

Por último, la distancia basada en la correlación tiene por fórmula:

$$d_{\text{correlacion}}(x_t, y_t) = \sqrt{2 \cdot (1 - \rho(\mathbf{x}_t, \mathbf{y}_t))} \quad (4.3)$$

Esta ecuación está definida en el intervalo $[0,2]$, donde los extremos se corresponden a los valores 1 y -1 en la correlación entre series temporales, respectivamente, y $\sqrt{2}$ cuando las series están incorrelacionadas.

Alternativamente utilizamos un parámetro para suavizarlo:

$$d_{\text{correlacion}} = \sqrt{\left(\frac{1 - \rho(\mathbf{x}_t, \mathbf{y}_t)}{1 + \rho(\mathbf{x}_t, \mathbf{y}_t)} \right)^\beta} \quad (4.4)$$

La distancia basada en la correlación es una medida de similitud que se utiliza comúnmente en la clasificación y el clustering de datos, ya que puede proporcionar información sobre la estructura de las relaciones entre las variables en un conjunto de datos. Además, esta medida de distancia es invariante a la escala, lo que significa que es adecuada para comparar conjuntos de datos que tienen diferentes magnitudes o escalas.

4.1.3. Distancia de DTWARP

La distancia de DTWARP (Dynamic Time Warping with Adaptive Rescaling and Shifting Penalty, en español, Deformación Dinámica del Tiempo) mide la similitud entre dos series temporales, teniendo en cuenta las posibles distorsiones en el tiempo y en la escala entre las dos series.

La fórmula para calcular la distancia de DTWARP entre dos series X e Y de longitud n y m respectivamente, se define como:

$$d_{\text{DTWARP}}(x_t, y_t) = \min_{r \in M} \left(\sum_{i=1}^m |x_{a_i} - y_{b_i}| \right) \quad (4.5)$$

donde M es el conjunto de todas las posibles secuencias de pares teniendo en cuenta el orden, es decir, $M = \{(x_{a_1}, y_{b_1}), \dots, (x_{a_m}, y_{b_m})\}$ con $a_i, b_i \in \{1, \dots, (N+L)\}$ tal que $a_1 = b_1 = 1$ y $a_m, b_m = (N+L)$, $a_{i+1} = (a_i \dot{O} a_{i+1})$ y $b_{i+1} = (b_i \dot{O} b_{i+1})$ para $i \in \{1, \dots, m-1\}$.

Esta distancia tiene en cuenta la posibilidad de que las dos series tengan diferentes estructuras temporales, y la posibilidad de que las distorsiones en el tiempo y la escala no sean uniformes en toda la serie. El resultado es una medida de distancia robusta y precisa que puede ser utilizada para comparar series temporales complejas en diferentes dominios de aplicación. El motivo porque el que esta distancia ignora la estructura temporal de los valores es porque está basada en los valores $|x_{a_i} - y_{b_i}|$, independientemente del crecimiento o decrecimiento alrededor de estos.

4.1.4. Distancia de CORT

La distancia de CORT (Correlation Optimized Warping) es una medida de distancia entre dos series de tiempo que permite encontrar la mejor alineación entre las dos series a través de una función basada en la correlación. Primero se define la función de *CORT* como

$$f_{\text{CORT}}(x_t, y_t) = \frac{\sum_{i=1}^{(N+L)-1} (x_{i+1} - x_i)(y_{i+1} - y_i)}{\sqrt{\sum_{i=1}^{(N+L)-1} (x_{i+1} - x_i)^2} \cdot \sqrt{\sum_{i=1}^{(N+L)-1} (y_{i+1} - y_i)^2}} \quad (4.6)$$

La función CORT se parece a la correlación entre las series temporales x_t y y_t , pero esta vez se aplican las diferencias $(x_{i+1} - x_i)$ y $(y_{i+1} - y_i)$, consideradas como relación lineal de primer orden entre vecinos en vez de tomar las diferencias $(x_i - \bar{x}_i)$ y $(y_i - \bar{y}_i)$.

El valor que toma f_{CORT} está en el intervalo $[-1, 1]$. El extremo de valor -1 significa que ambas series tienen un comportamiento en direcciones opuestas (una serie crece y la otra decrece, también respetando el mismo *ratio*) y el extremo 1 significa que ambas series tienen un comportamiento dinámico similar en la misma dirección (las dos series crecen y decrecen en los mismos momentos temporales y respetando el mismo *ratio*). En el centro del intervalo, cuando $f_{\text{CORT}} = 0$, significa que las series temporales x_t y y_t no tienen relación ninguna, ni en comportamiento ni en ratios de crecimiento.

Si se toma $\phi_k(u)$ como:

$$\phi_k(u) = \frac{2}{1 + \exp(ku)} \text{ con } k \geq 0 \quad (4.7)$$

Se define la fórmula de la distancia de *CORT* como:

$$d_{\text{CORT}}(x_t, y_t) = \phi_k[f_{\text{CORT}}(x_t, y_t)] \cdot d(x_t, y_t) \quad (4.8)$$

$d(x_t, y_t)$ es cualquier tipo de distancia de las mencionadas anteriormente. Para este proyecto se ha tomado la $d_{\text{euclídea}}$ definida en la fórmula 4.1.

Cuando $f_{\text{CORT}} = 0$ está próximo a 0, $\phi_k[f_{\text{CORT}}]$ tiende a 1, por lo que el factor $d(x_t, y_t)$ que mide la proximidad, adquiere importancia. Si $\phi_k[f_{\text{CORT}}] \approx 1$, la distancia $d(x_t, y_t)$ tiene poca consideración, provocando al factor $d_{\text{CORT}}(x_t, y_t)$ a ser 0. Por último, cuando $\phi_k[f_{\text{CORT}}] \approx -1$, la distancia $d(x_t, y_t)$ se amplifica con el factor $\phi_k[f_{\text{CORT}}]$. Se ha tomado $k = 2$ ya que es el valor que viene por defecto en *R*.

En resumen, la distancia de CORT es una medida de distancia que encuentra la mejor alineación entre dos series de tiempo a través de una función de costo basada en la correlación, y puede ser útil para comparar series que presentan diferencias en su forma o en su escala.

4.2. Selección de la distancia

Para crear los grupos se ha utilizado tanto el análisis de conglomerados jerárquico aglomerativo como la técnica de escalado multidimensional definidas en el Capítulo 1. En esta parte se relata la representación de las distancias y la elección de la más adecuada al problema.

Explicación teórica del escalado multidimensional

1. Se toma la matriz de distancias, D , y se calcula la matriz A como $a_{ij} = -\frac{d_{ij}^2}{2}$.
2. Con la matriz A , se calcula la matriz B mediante un proceso de doble centrado con la fórmula $b_{ij} = a_{ij} - \bar{a}_{i.} - \bar{a}_{.j} + \bar{a}_{..}$, donde se le resta a cada valor de A , todos los valores de cada columna y cada línea.
3. Se diagonaliza B , expresándola como $B = C\lambda C^t = XX^t$ donde $X = C\lambda^{1/2}$ donde λ es la matriz diagonal formada por los autovalores estrictamente positivos de B y donde C es la matriz formada por los correspondientes autovectores unitarios.
4. La matriz X son las coordenadas en dimensión 2 de los puntos a representar.

Aplicación al conjunto de datos del *winrate*

Se aplican las distancias definidas en el apartado 4.1 a los datos obtenidos del *winrate* de los campeones y se obtienen los gráficos 4.1. Como se puede comprobar, los tres métodos agrupan de manera similar. Se encuentra un grupo enorme que se sitúa en la parte de abajo a la izquierda que corresponde en su mayoría con campeones que son antiguos y están bastante balanceados y no han sufrido grandes cambios. Por otro lado los que están alejados de este grupo son principalmente campeones más nuevos y en los extremos de las cuatro gráficas aparecen los mismos.




Figura 4.1: Escalado multidimensional distancia euclídea, basada en correlaciones, DTWARP y CORT aplicada al *winrate*

Fuente: Elaboración propia

Aplicación al conjunto de datos del *banrate*

Se decide utilizar la distancia *CORT* ya que contempla el comportamiento de los datos y su proximidad. Estas características se valoran mucho al decidir que dos campeones se comportan parecido. Un campeón que tiene estadísticas similares, de las dos que se analizan, es exactamente igual que otro. Por ejemplo, si se compara el ratio selección de un campeón aunque la diferencia de selección es muy grande, lo que indica que la distancia euclídea es muy alta, puede llegar a indicar que el campeón se selecciona o se pone de moda a la vez que el otro, porque uno llegue a contrarrestar las habilidades del otro y la distancia *CORT* es pequeña. Si se compara el porcentaje de victorias, dos campeones pueden tener valores similares ya que se utilicen muy bien juntos y sean complementarios en un equipo. En el caso del *banrate*, dos personajes que ven un aumento en su eliminación indica que los dos se ponen de moda en las mismas, por ejemplo, por los cambios en los objetos que utilizan ambos.

Por otro lado, dos campeones con datos muy similares, que viene indicado la distancia euclídea es baja, pueden tener comportamiento muy diferente u opuesto que indica que los campeones no tienen relación, pudiendo ser la distancia *CORT* grande, ya que estos campeones comparten datos similares pero no funcionan bien juntos y no escalan o decrecen a la vez.




Figura 4.2: Escalado multidimensional distancia euclídea, basada en correlaciones, DTWARP y CORT aplicada al *banrate*

Fuente: Elaboración propia

4.3. Elección del encadenamiento

Como se ha definido anteriormente, es necesario una medida de similitud entre las observaciones, como una distancia y un encadenamiento o norma que sirve para comparar entre las observaciones y las agrupaciones creadas.

Como encadenamientos se encuentran:

- **Encadenamiento simple:** la distancia entre grupos se mide como la distancia entre los dos elementos de cada grupo más próximos entre sí. Es útil cuando se trabaja con datos que tienen clusters que se solapan o que tienen diferentes densidades. Debido a que se basa en la distancia entre los objetos más cercanos de dos clusters, puede capturar la estructura de los datos de manera más precisa y formar clusters que se ajustan a la forma real de los datos.

Sin embargo, puede ser menos adecuado para datos que tienen clusters muy separados y bien definidos, ya que puede unir objetos que no son realmente similares si están cerca de los límites de dos clusters.

En general, se recomienda usar el encadenamiento simple cuando se tienen datos que se sabe que forman clusters que se solapan o que tienen estructuras más complejas, y cuando se desea formar clusters alargados y con formas no esféricas. No es adecuado si los clusters están muy separados o tienen formas más compactas.

- **Encadenamiento de centroides:** la distancia entre grupos es la distancia entre los centroides (punto equidistante a los demás) de los grupos. Es adecuado para datos que tienen un número elevado de dimensiones, ya que el cálculo de los centroides puede reducir la dimensionalidad y simplificar el cálculo de las distancias entre los objetos.

Este método también es menos sensible a la presencia de valores atípicos en comparación con otros métodos de encadenamiento, por lo que puede ser una buena opción cuando se sospecha que hay valores atípicos en los datos.

Sin embargo, el encadenamiento de centroides puede no ser adecuado para datos con estructuras complejas, como clusters con formas no esféricas o con diferentes densidades.

- **Encadenamiento de medias:** la distancia entre grupos es la media de las distancias entre parejas de elementos tomando uno de cada grupo. Es especialmente adecuado para datos que tienen estructuras jerárquicas claras y para los que se desea formar clusters con formas esféricas y compactas. Es particularmente útil para la clasificación de organismos en taxonomía, ya que se basa en la similitud genética de las especies y se puede representar en forma de un árbol filogenético.

Sin embargo, el encadenamiento de medias puede no ser adecuado para datos que tienen clusters con formas no esféricas o para los que los objetos están muy separados entre sí. Además, puede ser sensible a valores atípicos o errores de medición.

En general, se recomienda utilizar el encadenamiento de medias cuando se tiene un conjunto de datos con una estructura jerárquica clara y se desea formar clusters esféricos y compactos. No es adecuado si los datos tienen clusters con formas no esféricas o están muy separados.

- **Encadenamiento de *Ward*:** se toma como grupo de unión aquella pareja de grupos cuya varianza es mínima tras haber juntado los dos grupos. Es una buena opción cuando se desea encontrar grupos compactos y con formas más o menos esféricas. Esto se debe a que el método de *Ward* minimiza la varianza total dentro de cada grupo, por lo que tiende a formar grupos más homogéneos en términos de varianza. También es útil cuando se tienen datos numéricos y se desea una partición jerárquica en la que los grupos se definan por sus relaciones euclidianas entre las variables.

En general, el método de *Ward* es adecuado para conjuntos de datos grandes y complejos en los que se desea una partición en grupos compactos y bien definidos, pero puede ser menos apropiado para conjuntos de datos con grupos que tienen formas irregulares o no esféricas. Además, debido a que el método de *Ward* es sensible a los valores atípicos, puede ser menos adecuado para conjuntos de datos con valores atípicos o datos extremos.

- **Encadenamiento *complete*:** la distancia entre grupos es la distancia entre los dos elementos de cada uno más alejados entre sí. Es especialmente útil cuando se trabaja con datos que tienen clusters con formas no esféricas o con diferentes densidades. Debido a que se basa en la distancia entre los objetos más alejados de dos clusters, puede unir clusters separados por regiones de baja densidad o de diferentes densidades.

Sin embargo, el encadenamiento *complete* puede ser menos adecuado para datos que tienen clusters que se solapan o que tienen estructuras más complejas, ya que puede unir objetos que no son realmente similares si están cerca de los límites de dos clusters.

En general, se recomienda usar el encadenamiento *complete* cuando se tienen datos que se sabe que forman clusters muy separados y bien definidos, y cuando se desea formar clusters compactos y aislados. No es adecuado si los clusters no están bien separados o tienen estructuras más complejas.

Todos los tipos de encadenamiento descritos producen resultados similares si se da el caso de que los datos tengan una fuerte tendencia a la agrupación. En caso contrario, las agrupaciones obtenidas varían mucho entre los distintos encadenamientos. El encadenamiento simple tiende a agrupar muy rápido dos grupos,

mientras que el *complete* puede agrupar observaciones que no sean tan cercanas entre sí como con otras de otros grupos más cercanos. Los encadenamientos de medias, centroides y Ward, son los más razonables ya que están entre estos dos extremos. La agrupación en la distancia euclídea quiere decir que las series están próximas en la distancia de medir, pero puede que el comportamiento sea muy diferente. Para la distancia basada en correlaciones, la agrupación indica que las series tienen un comportamiento muy similar independientemente de la ratio de crecimiento. En el caso de la distancia *DTWARP*, los datos se agrupan bastante centrados lo que indica que el comportamiento de estos grupos se asemeja entre ellos independientemente de la escala del tiempo definida. Por último, para la distancia *CORT* se forman grupos similares que para la distancia euclídea aunque la interpretación difiere al contemplar la proximidad de las series y el comportamiento.

Explicación teórica del análisis de conglomerados jerárquico aglomerativo

1. Se toma la matriz de distancias D entre elementos (individuales o grupos).
2. Se buscan los elementos con menor distancia entre ellos y se agrupan.
3. Se recalculan las distancias del nuevo grupo con respecto a los demás elementos, empleando el encadenamiento elegido.
4. Se repiten los pasos 2 y 3 hasta que solamente quede un único grupo.

Gracias al método jerárquico aglomerativo en *R*, se puede crear una gráfica del proceso llamada dendrograma con la que se puede observar el momento en que se unen dos elementos y la proximidad entre ellos. Tras aplicar las técnicas a los datos, una forma para elegir la distancia y el encadenamiento es generar automáticamente un documento, en este caso en formato *.pdf* en el que cada hoja represente a una de las distancias y, en ella, aparezcan ordenados todos los encadenamientos.

Esta imagen muestra un ejemplo de la aplicación del análisis de conglomerados generada por el código de *R* aplicado a las distintas distancias [4.3](#).

4.4. Elección de los representantes

Una vez obtenidos los grupos de cada serie temporal, el último paso para completar el proceso de reducción de dimensión es elegir aquella serie de los grupos que mejor lo represente. En este paso es importante tener en cuenta que las técnicas a emplear. La estrategia que se propone en este trabajo ha sido tomar




Figura 4.3: Encadenamiento de centroides aplicada a las cuatro distancias del conjunto de *winrate*

Fuente: Elaboración propia

como representante aquella serie cuya distancia CORT a la serie media del grupo fuera la menor, siendo la serie media del grupo la que se define como:

$$\left(\frac{(x_1^1 + \dots + x_1^k)}{k}, \dots, \frac{(x_{N+L}^1 + \dots + x_{N+L}^k)}{k} \right) \quad (4.9)$$

con k la cantidad de series temporales en el grupo y $N + L$ la cantidad de observaciones de cada una de las ellas. La distancia utilizada es CORT por haber sido la utilizada por los grupos, si se hubieran hecho con otra, habría que haber seleccionado dicha distancia.

4.5. Creación de grupos

A continuación se observa la aplicación de la distancia de CORT a las distintas estadísticas y los diferentes grupos que se han creado. La cantidad de grupos, se obtiene con la generación automática un *.pdf* con los posibles grupos según la cantidad de cortes.

Aplicación al conjunto de datos del *winrate*

Se decide utilizar el encadenamiento de *Ward*, ya que la gráfica 4.1 indica una nube de puntos esférica alrededor de un centro. Se ha descartado la opción del encadenamiento *complete* ya que los datos no están muy separados e independientes y se puede unir campeones que no son realmente similares si están cerca de los límites de dos clusters. Tampoco es adecuado el de centroides porque los grupos tienen diferentes densidades, al igual que el encadenamiento de medias. El encadenamiento simple queda descartado ya que las formas son esféricas. Al




Figura 4.4: Creación de grupos de *winrate* con distancia *CORT* y encadenamiento de *Ward*

Fuente: Elaboración propia

minimizar la varianza total dentro de cada grupo, estos son más homogéneos y no presentan muchas diferencias fuera de la media.

Tras aplicarle los métodos de agrupación el dendrograma queda de la siguiente manera 4.4.

Se puede comprobar que se han formado cinco grupos. Se ha utilizado otro código para cambiar la forma del dendrograma y observar los integrantes de cada grupos en 4.5.

Sobre esta agrupación, se aprecia que la mayoría de personajes varían de la misma manera, lo que explica que el juego esta bastante equilibrado ya que cuando un campeón obtiene altas tasas de victorias, se rebajan sus estadísticas para que no se vuelva muy poderoso y en caso de que pierda muchas partidas se suben estas estadísticas. En el grupo verde por ejemplo, encontramos casos de campeones que




Figura 4.5: Grupos formados de *winrate* con distancia *CORT* y encadenamiento de *Ward*

Fuente: Elaboración propia

funcionan bien juntos, como es el caso de *Kog'Maw* y *Lulu* que se juegan juntos en la línea de abajo y cada vez que se pone de moda *Kog'Maw*, *Lulu* ve afectada su tasa de victorias y derrotas, lo que ocurre también en el caso de *Caitlyn* y *Morgana*. Esto pasa en el grupo negro con *Kalista* y *Braum*. En el grupo verde se observa que hay campeones que funcionan muy bien con un tipo de personajes en concreto, por ejemplo *Morgana* y *Lulu* que son personajes encargados de proteger a los que más daño hacen en las partidas cómo son los mencionados anteriormente o campeones similares como *Jinx* o *Ashe*. En el grupo naranja ocurre lo mismo, los personajes que se juegan en la línea inferior como daño, que son *Jhin*, *Tristana* o *Vayne*, que se ven beneficiados por apoyos que son más agresivos como *Bardo* o *Thresh*. En el grupo azul podemos apreciar campeones que han sido modificados recientemente ya que tenían habilidades muy poderosas en algunos momentos del juego como *Irelia* o *Akali* o porque estaban un poco desfasados como es el caso de *Evelynn*.

Tras aplicar la fórmula los grupos quedan representados por:

- **Grupo color rojo:** *Malphite*
- **Grupo color azul:** *Jayce*
- **Grupo color negro:** *Taliyah*
- **Grupo color verde:** *Morgana*
- **Grupo color naranja:** *Rek'Sai*

Las series de estos campeones 4.6 serán las series temporales representativas.

Aplicación al conjunto de datos del *banrate*

Al comprobar la gráfica 4.2, al igual que en el caso anterior, se decide utilizar el encadenamiento de *Ward*.

Tras aplicarle los métodos de agrupación el dendograma queda de la siguiente manera 4.7.

Se puede comprobar que también se han formado cinco grupos. Con el otro código, los integrantes de cada grupo queda 4.8.

En este caso, aparte de las razones de agrupación anteriores, se suma que hay tipos de objetos clave que utilizan varios personajes, entonces cambios en estos objetos, implica que esos personajes se ponen de moda, lo que significa un aumento en su bloqueo. Estos casos se pueden apreciar en el grupo rojo, por ejemplo, con personajes como *Shaco*, *Nocturne*, *Pantheon* que cobran el rol de asesino en la posición de jungla o en el grupo azul con *Sejuani*, *Maokai*, *Gragas* que




Figura 4.6: Series de los representantes de los grupos para el *winrate*
Fuente: Elaboración propia

cobran el rol de tanque en la posición de jungla. En el grupo negro, encontramos a los campeones que se eliminan bastante poco en las partidas.

Tras aplicar la fórmula los grupos quedan representados por:

- **Grupo color rojo:** *Shaco*
- **Grupo color azul:** *Zilean*
- **Grupo color verde:** *Alistar*
- **Grupo color negro:** *Shen*
- **Grupo color naranja:** *Illaoi*

Las series de estos campeones [4.6](#) serán las series temporales representantes.




Figura 4.7: Creación de grupos de *banrate* con distancia *CORT* y encadenamiento de *Ward*

Fuente: Elaboración propia




Figura 4.9: Series de los representantes de los grupos para el *banrate*
Fuente: Elaboración propia

5

Técnicas de predicción

Este capítulo trata de la predicción de las series temporales representantes de cada estadística. Para ello, se han empleado diversas técnicas de predicción, entre las que se encuentran las propias de las series temporales como ARIMA y TBATS, así como aquellas que utilizan datos de sección cruzada como las redes neuronales o k vecinos más cercanos. Además, se ha llevado a cabo un proceso de experimentación para lograr un modelo óptimo, incluyendo la combinación de las predicciones de los otros modelos.

Las técnicas que se enseñan utilizando datos de sección cruzada se enfocan exclusivamente en la predicción de variables continuas, que se conoce como el problema de regresión, y no en la predicción de variables categóricas, lo que se conoce como problema de clasificación. Esto se debe a que la predicción de series temporales se trata de un problema de predicción y no de clasificación.

5.1. Introducción a la predicción de series temporales

Se definen cuatro aspectos importantes para la predicción

5.1.1. Creación de los conjuntos de entrenamiento y de prueba

Para proceder con la predicción, se ha dividido el conjunto de datos inicial en dos conjuntos:

- **Conjunto de entrenamiento:** compuesto por los $N = 123$ primeros datos de la serie temporal y es con el que se entrena el modelo.
- **Conjunto de prueba:** compuesto por los $K = 7$ datos temporales restantes y se utiliza para medir la fiabilidad de la predicción.

5.1.2. Creación de variables auxiliares

Se van a utilizar un conjunto de variables para incorporar mayor información en el modelo para aumentar su fiabilidad.

- **Variables escalón:** suelen utilizarse para representar cambios significativos y conocidos en las condiciones de recopilación de datos. Su función es asignar el valor de uno durante el período en que se produce el cambio y cero en los demás momentos temporales. Por ejemplo, si se ha realizado una revisión completa de las habilidades de un campeón que se mantiene vigente desde 2018, se podría modelizar el cambio utilizando estas variables, asignando un uno en todos los momentos temporales desde 2019 hasta la fecha actual, y completando con ceros los momentos previos a ese cambio.
- **Variable de valor atípico:** se utilizan comúnmente cuando los datos pueden ser o son considerados atípicos, de manera que se asigna un uno en el momento temporal en el que se presenta el valor atípico y un cero en los demás momentos. Por ejemplo, si se produce un cambio menor en un personaje durante la segunda semana de enero de 2020, se podría utilizar una variable de valor atípico asignando un uno en ese momento temporal y rellenando el resto con ceros.
- **Variable de medias móviles:** se utiliza para determinar la tendencia de una serie temporal. Su cálculo se realiza mediante la obtención de la media de los datos de la serie, luego de dividirlos en bloques de longitud l . De esta manera, se puede obtener información valiosa sobre la tendencia de la serie, lo que puede resultar de gran utilidad en el análisis y la predicción de los datos.

5.1.3. Procesamiento de las series temporales

Con el fin de aplicar diversas técnicas de predicción utilizando datos de sección cruzada, se establece una perspectiva que permite adaptar algunos de los algoritmos de regresión a la predicción de series temporales. Esto resulta útil para poder aplicar técnicas de regresión a este tipo de problemas y obtener predicciones precisas y confiables sobre la evolución de los datos en el futuro.

Se parte de un conjunto de p variables explicativas $X_1, \dots, X_p$ y como salida la variable respuesta Y . Se define como M el modelo:

$$Y = M(X_1, \dots, X_p) \quad (5.1)$$

Como el objetivo es predecir el futuro, se parte de una serie temporal $y_t, y_{t-1}, y_{t-2}, \dots, y_0$, utilizando como referencia los valores presentes y pasados. Se hace depender y_t de sus p retardos, $y_t, y_{t-1}, y_{t-2}, \dots, y_{t-p}$, quedando entonces la fórmula como:

$$y_t = M(y_t, y_{t-1}, y_{t-2}, \dots, y_{t-p}) \quad (5.2)$$

Para entrenar el modelo M , la forma en que se deben procesar los datos de la serie temporal es en bloques $(y_t, y_{t-1}, y_{t-2}, \dots, y_{t-p}; y_t)$, es este caso, $p = 7$, por lo que, por ejemplo, y_8 se explica gracias a las variables $(y_1, y_2, y_3, y_4, y_5, y_6, y_7)$. En el caso de las variables a predecir, $\hat{y}_{130}$ se explica gracias a $(y_{123}, \hat{y}_{124}, \hat{y}_{125}, \hat{y}_{126}, \hat{y}_{127}, \hat{y}_{128}, \hat{y}_{129})$, donde $\hat{y}_n$ denota variables predecidas.

Si hay variables auxiliares, también se añaden como variables explicativas con sus respectivos retardos, como en la técnica descrita más adelante llamada *SVM*.

Este procesamiento de los datos descrito se llama estrategia recursiva. Existen otras estrategias, como la estrategia *MIMO*, explicada más adelante, para la técnica de k vecinos más próximos.

Una vez entrenado el modelo, para predecir, se sustituyen valores de los retardos. Para la predicción en el momento $(N + L + 1)$; $\hat{y}_{N+1}$, se toman los valores en los p retardos anteriores $(y_N, y_{N-1}, \dots, y_{N-(p+1)})$ que pertenecen al conjunto de datos de entrenamiento. En la predicción $\hat{y}_{N+2}$, se toman tanto los datos del conjunto de entrenamiento como la primera predicción, $\hat{y}_{N+1}$ y así sucesivamente.

5.1.4. Definición de los estadísticos comparadores

Una vez creado el modelo, se debe comprobar la fiabilidad de este, comparando las predicciones con los datos reales del conjunto de prueba. Ante la gran canti-

dad de estadísticos de comparación existentes, se ha optado por tomar el Error Cuadrático Medio (ECM) y el Error Absoluto Medio (EAM) por su sencillez y su presencia habitual en la comparación de series temporales. Se define el Error Cuadrático Medio como:

$$\varepsilon_{cuadrático\ medio} = \sqrt{\frac{1}{L} \sum_{i=1}^L (\hat{y}_{N+i} - y_{N+i})^2} \quad (5.3)$$

Se define el Error Medio Absoluto como:

$$\varepsilon_{medio\ absoluto} = \frac{1}{L} \sum_{i=1}^L |\hat{y}_{N+i} - y_{N+i}| \quad (5.4)$$

Una vez definidos los aspectos a tener en cuenta, se procede a dar una breve introducción a cada modelo utilizado para la predicción. No se ha indagado mucho en el aspecto más teórico de como funciona el modelo. Para ampliar este conocimiento se deja como referencia [8] y para saber el funcionamiento interno de los modelos se puede consultar [9].

5.2. Modelo *SARIMA*

El modelo *SARIMA*, *Seasonal Autoregressive Integrated Moving Average* es una extensión del modelo *ARIMA*, *Autoregressive Integrated Moving Average*, que incorpora la capacidad de modelar datos que tienen patrones estacionales.

SARIMA se utiliza para modelar una serie temporal estacionaria que muestra patrones de autocorrelación, estacionalidad y heterocedasticidad. La estructura del modelo se compone de tres partes:

- La parte *ARIMA* que modela la estructura de la serie temporal.
- La parte estacional que modela los patrones estacionales en la serie temporal.
- La parte de error que modela los errores de la predicción.

La notación para el modelo *SARIMA* se compone de cuatro elementos *SARIMA* (p, d, q)(P, D, Q)_s, donde:

- p: orden del modelo autorregresivo (AR)




Figura 5.1: Comparación de el conjunto de datos de entrenamiento, verde y las predicciones por el modelo *SARIMA*, azul, para el *winrate*

Fuente: Elaboración propia

- d: orden de integración (I)
- q: orden del modelo de medias móviles (MA)
- P: orden del componente AR estacional
- D: orden de integración estacional
- Q: orden del componente MA estacional
- s: longitud del ciclo estacional (en este caso de 26, al ser un periodo bise-manal en un año)

Aplicación al conjunto de datos del *winrate*

Se puede observar, según la figura 5.1 que para *Jayce* y *Rek'Sai* el ajuste obtenido con el modelo *SARIMA* no es muy preciso pero aún mantiene la tendencia, mientras que para *Morgana* el ajuste es bastante preciso manteniendose la forma y la tendencia. En el caso de *Taliyah* y *Malphite*, aunque se mantiene la tendencia en algunos casos, el ajuste obtenido es bastante malo. La figura 5.2 muestra las predicciones fuera de los entrenamientos, donde se refleja lo esperado previamente, aunque en el caso de *Morgana* las predicciones no son tan precisas como se esperaba. La tabla 5.1 refleja los errores obtenidos.

Aplicación al conjunto de datos del *banrate*

En este caso, se puede observar que el ajuste más preciso es el de *Illaoi*, mientras que el ajuste para *Zilean* no es muy preciso pero mantiene la tendencia.




Figura 5.2: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo *SARIMA*, azul y los datos de prueba, morado, para el *winrate*

Fuente: Elaboración propia

Jayce		Rek'Sai		Taliyah		Malphite		Morgana	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
0.916	0.849	0.720	0.667	1.007	0.837	1.057	0.718	0.355	0.316

Tabla 5.1: ECM y EAM obtenidos con el modelo *SARIMA* para el *winrate*

Sin embargo, en el caso de *Shen*, *Shaco* y *Alistar*, aunque se mantiene la tendencia en algunos casos, el ajuste es bastante malo. Al analizar las predicciones fuera de los entrenamientos en la figura 5.3, se puede observar que se refleja lo esperado anteriormente, pero en el caso de *Illaoi* se mantiene por debajo pero con la misma tendencia. La tabla 5.2 refleja los errores obtenidos.

5.3. Modelo *TBATS*

TBATS, *Trigonometric seasonality*, *Box-Cox transformation*, *ARMA errors*, *Trend and Seasonal components*, es un modelo de series temporales que combina varias técnicas para modelar y predecir datos que tienen patrones de estacionalidad complejos y no lineales.

Está formado por cuatro componentes principales:

- La transformación de *Box-Cox*, que se utiliza para estabilizar la varianza de la serie temporal.
- El componente de tendencia, que modela cualquier tendencia o cambio de nivel en la serie temporal.




Figura 5.3: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo *SARIMA*, azul y los datos de prueba, morado, para el *banrate*

Fuente: Elaboración propia

Shaco		Zilean		Alistar		Shen		Illaoi	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
1.574	1.448	0.543	0.518	2.757	2.582	2.204	1.991	0.289	0.257

Tabla 5.2: ECM y EAM obtenidos con el modelo *SARIMA* para el *banrate*

- El componente de estacionalidad, que modela cualquier patrón de estacionalidad en la serie temporal utilizando funciones trigonométricas.
- El componente de errores ARIMA, descrito anteriormente, que modela cualquier correlación entre los errores en el tiempo.

Una ventaja del modelo *TBATS* es que puede manejar patrones de estacionalidad múltiples y complejos, como estacionalidad anual, trimestral y mensual simultáneamente. Además, puede manejar series temporales con tendencias no lineales, lo que lo hace útil para predecir datos en campos como finanzas, marketing y economía.

Aplicación al conjunto de datos del *winrate*

Se puede comprobar en la figura 5.4 que ocurre algo similar al modelo anterior ya que para *Jayce* y *Rek'Sai* el ajuste sigue sin ser muy preciso aunque este mantenga la tendencia. En el caso *Morgana* el ajuste vuelve a ser bastante preciso al mantenerse tanto la forma como la tendencia. Pero en el caso de *Taliyah* y *Malphite* el ajuste es bastante pobre ya que no se mantiene la forma. La figura



Figura 5.4: Comparación de el conjunto de datos de entrenamiento, verde y las predicciones por el modelo *TBATS*, azul, para el *winrate*

Fuente: Elaboración propia

5.5 refleja las predicciones fuera de los entrenamientos, donde se refleja lo esperado anteriormente, pero en el caso de *Morgana* es peor que lo esperado. La tabla 5.3 refleja los errores obtenidos.

Aplicación al conjunto de datos del *banrate*

La figura 5.6 refleja las predicciones fuera de los entrenamientos, y se comprueba que *Shaco*, *Zilean*, *Alistar* y *Illaoi* tienen valores y tendencias muy cercanas a la realidad mientras que *Shen* difiere bastante. La tabla 5.4 refleja los errores obtenidos.




Figura 5.5: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo *TBATS*, azul y los datos de prueba, morado, para el *winrate*

Fuente: Elaboración propia

Jayce		Rek'Sai		Taliyah		Malphite		Morgana	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
0.996	0.908	0.618	0.493	0.760	0.554	1.921	1.607	1.452	1.376

Tabla 5.3: ECM y EAM obtenidos con el modelo *TBATS* para el *winrate*




Figura 5.6: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo *TBATS*, azul y los datos de prueba, morado, para el *banrate*

Fuente: Elaboración propia

5.4. Modelo de redes neuronales autorregresivas

Las redes neuronales autorregresivas, también conocidas como *Autoregressive Neural Networks*, son una herramienta para predecir y modelar series temporales. A diferencia de otros modelos que se basan en el análisis estadístico, las redes neuronales *ARN* emplean una estructura de redes neuronales para aprender y modelar los patrones de la serie temporal.

En la red neuronal autorregresiva, la entrada en cada paso de tiempo es la observación más reciente y la salida es la predicción del siguiente valor en la serie temporal. La red se entrena para establecer la relación entre los valores previos y el valor actual de la serie temporal, lo que permite hacer

Las redes neuronales autorregresivas tienen la ventaja de poder capturar patrones complejos y no lineales en las series temporales, lo que las hace útiles en muchas aplicaciones. Además, son capaces de manejar datos faltantes y ruido en la serie temporal. A pesar de estas ventajas, es importante tener en cuenta que

Shaco		Zilean		Alistar		Shen		Illaoi	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
0.706	0.682	0.232	0.197	0.480	0.433	3.667	3.586	0.304	0.273

Tabla 5.4: ECM y EAM obtenidos con el modelo *TBATS* para el *banrate*

Jayce		Rek'Sai		Taliyah		Malphite		Morgana	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
1.489	0.941	1.123	0.924	0.733	0.618	2.630	2.193	1.293	1.378

Tabla 5.5: ECM y EAM obtenidos con el modelo *ARNN* para el *winrate*

las redes neuronales autorregresivas pueden ser computacionalmente intensivas y requerir grandes conjuntos de datos para obtener resultados precisos. También es importante tener en cuenta que debido a su capacidad de ajuste, pueden sufrir de sobreajuste y requerir técnicas de regularización para obtener resultados precisos en datos no vistos.

En general, las redes neuronales autorregresivas son una técnica de modelado útil para series temporales complejas y no lineales, pero su uso requiere un cuidadoso ajuste y selección de parámetros para obtener resultados precisos. Además, en los últimos años se ha visto un gran avance en el uso de redes neuronales para modelos de series temporales, incluyendo técnicas como redes neuronales recurrentes y redes neuronales convolucionales que pueden mejorar aún más la precisión de las predicciones.

Aplicación al conjunto de datos del *winrate*

Se puede comprobar en la figura 5.7 que para *Morgana*, *Jayce* y *Rek'Sai* que la tendencia es similar mientras que el ajuste no es muy preciso. En el caso concreto de *Malphite* contempla el peor ajuste de todos y en el caso de *Taliyah* se ha mejorado. La gráfica 5.8 refleja las predicciones fuera de los entrenamientos, donde se comprueban estos aspectos. La tabla 5.5 refleja los errores obtenidos.

Aplicación al conjunto de datos del *banrate*

La gráfica 5.6 refleja las predicciones fuera de los entrenamientos, y se comprueba que *Illaoi* y *Zilean* y tienen valores y tendencias cercanos a la realidad, *Alistar* *Shaco* están bastante alejados y *Shen* sigue con un error de predicción bastante alto.

La tabla 5.6 refleja los errores obtenidos.

Fuente: Elaboración propia



Figura 5.8: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo *ARNN*, azul y los datos de prueba, morado, para el *winrate*

Fuente: Elaboración propia




Figura 5.9: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo *ARNN*, azul y los datos de prueba, morado, para el *banrate*

Fuente: Elaboración propia

Shaco		Zilean		Alistar		Shen		Illaoi	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
2.900	2.080	0.533	0.488	6.618	5.674	6.699	6.625	1.104	0.886

Tabla 5.6: ECM y EAM obtenidos con el modelo *ARNN* para el *banrate*

5.5. Modelo de los k vecinos más próximos

El modelo de los k vecinos más próximos, *K-Nearest Neighbors*, es un algoritmo de aprendizaje automático supervisado utilizado para clasificación y regresión.

El modelo *K-NN* clasifica o predice la variable objetivo de un punto de datos basándose en las observaciones etiquetadas más cercanas a él en el espacio de características. Es decir, se calcula la distancia entre el punto de datos de entrada y los puntos de datos de entrenamiento más cercanos, y utiliza las etiquetas de clase o valores de variable objetivo correspondientes de los k puntos de datos más cercanos para clasificar o predecir el punto de datos de entrada.

El valor de *k* se refiere al número de datos más cercanos que se utilizan para la clasificación o predicción. Un valor pequeño de *k* puede llevar a un modelo con alta variabilidad, mientras que un valor grande de *k* puede llevar a un modelo con alta sesgo.

El modelo *K-NN* no requiere una etapa de entrenamiento compleja. Además, es útil cuando la estructura subyacente de los datos es desconocida o cuando no es

fácilmente modelable. Sin embargo, puede ser computacionalmente intensivo y su rendimiento puede ser sensible a la elección de la métrica de distancia utilizada.

En resumen, es una técnica útil de aprendizaje automático para la clasificación y predicción que utiliza los puntos de datos etiquetados más cercanos para hacer predicciones.

Con este modelo, se utilizan dos estrategias:

Estrategia recursiva o iterativa

Es el enfoque utilizado por los modelos *SARIMA* y *TBATS* para pronosticar varios momentos temporales. Básicamente, se utiliza un modelo que sólo pronostica un único dato a futuro (la variable respuesta solamente es una), de modo que dicho modelo se aplica de manera iterativa para pronosticar todos los datos futuros. Si hay retardos que se utilizan para predecir la observación que no están disponibles en el conjunto de entrenamiento, se utilizan las propias predicciones anteriores prolongando la serie de entrenamiento.

Estrategia de “Múltiple entrada, múltiple salida”

Esta estrategia se aplica comúnmente con el modelo de k vecinos más próximos y se caracteriza por obtener un modelo que predice un conjunto de valores a la vez, en vez de solamente uno.

De esta manera, la variable objetivo es un vector de longitud igual al número de predicciones que se desean realizar. Para utilizar esta estrategia, la serie temporal se divide de manera diferente a como se explicó anteriormente. En lugar de dividir la serie en p retardos, $p = 7$ en este caso, que actúan como variables explicativas, y un valor como variable objetivo, se divide en p retardos que actúan como variables explicativas y L valores adelantados, $L = 7$ en este caso, como variables objetivo. Después de encontrar los k vectores de retardos más cercanos, $k = 12$ en este caso, se calcula una media ordenada elemento por elemento con los L valores adelantados de todos ellos.

Es importante tener en cuenta que no se deben confundir los valores: k se refiere a la cantidad de vecinos cercanos, L se refiere a la cantidad de predicciones y p se refiere a los retardos.

Se deja como referencia [10] en caso de que se quiera profundizar más en estas estrategias de manera visual.



Figura 5.10: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de k vecinos más próximos recursivo, azul y los datos de prueba, morado, para el *winrate*

Fuente: Elaboración propia

Aplicación al conjunto de datos del *winrate*

La gráfica 5.10 refleja las predicciones para el modelo recursivo fuera de los entrenamientos, y se comprueba que *Jayce* obtiene valores por encima de los reales, *Malphite* por debajo y aunque si la misma tendencia, *Morgana* por debajo y también se observa la tendencia y *Taliyah* y *Rek'Sai* tiene tendencias similares.

La tabla 5.7 refleja los errores obtenidos.

Las predicciones para el modelo recursivo y *MIMO* fuera de los entrenamientos se muestran en las figuras 5.10 y 5.11 respectivamente. Se observa que *Jayce* tiene valores por encima de los reales en ambas gráficas, mientras que *Malphite* está por debajo. *Morgana* y *Taliyah* también tienen valores por debajo en ambas gráficas, aunque mantienen la misma tendencia. Por otro lado, *Rek'Sai* muestra una tendencia similar en ambas gráficas. Los errores obtenidos se muestran en las tablas 5.7 y 5.8. Es importante destacar que estos resultados son solo una aproximación y pueden requerir ajustes adicionales para mejorar la precisión de las predicciones.

5.5. Modelo de los k vecinos más próximos



Figura 5.11: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de k vecinos más próximos *MIMO*, azul y los datos de prueba, morado, para el *winrate*

Fuente: Elaboración propia




Figura 5.12: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de k vecinos más próximos recursivo, azul y los datos de prueba, morado, para el *banrate*

Fuente: Elaboración propia

Jayce		Rek'Sai		Taliyah		Malphite		Morgana	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
0.898	0.776	1.313	1.224	0.521	0.413	0.860	0.713	0.480	0.401

Tabla 5.7: ECM y EAM obtenidos con el modelo K -NN Recursivo para el *winrate*

Jayce		Rek'Sai		Taliyah		Malphite		Morgana	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
0.785	0.519	1.364	1.279	0.778	0.678	1.137	0.840	0.740	0.633

Tabla 5.8: ECM y EAM obtenidos con el modelo K -NN MIMO para el *winrate*

Aplicación al conjunto de datos del *banrate*

La gráfica 5.12 refleja las predicciones para el modelo recursivo fuera de los entrenamientos, se comprueba que *Alistar* y *Shaco* tienen valores y tendencias demasiados cercanos a la realidad, *Illaoi* y *Zilean* se acercan bastante y *Shen* sigue con bastante error de predicción.

En este conjunto, la predicciones fuera de los entrenamientos se muestran en las figuras 5.12 y 5.13 respectivamente. En el caso recursivo, se observa que *Shaco* tienen valores y tendencias demasiado cercano a la realidad mientras que *Alistar*, *Illaoi* y *Zilean* se acercan bastante. Por otro lado *Shen* tiene bastante error de predicción. En el caso MIMO, se comprueba que *Zilean* y *Shaco* tienen los datos prededidos más cercanos a los de entrenamiento. Los datos de *Illaoi* y *Alistar* se acercan bastante la realidad pero *Shen* sigue arrojando valores lejanos a lo esperado. Los errores obtenidos se muestran en las tablas 5.9 y 5.10.

5.6. Combinación de predicciones

En última instancia, se utiliza el enfoque de combinar las predicciones de las técnicas previas, lo que permite incorporar características únicas de cada modelo en la predicción final. Aunque esta técnica requiere el ajuste de varios modelos antes de obtener un modelo definitivo, puede mejorar las predicciones de los modelos únicos. Aunque el ajuste de varios modelos puede llevar más tiempo y memoria computacional, esta técnica puede ser muy útil en la mejora de la precisión de las predicciones y la reducción de errores en la predicción de series temporales.

Como combinaciones se utilizan




Figura 5.13: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de k vecinos más próximos *MIMO*, azul y los datos de prueba, morado, para el *banrate*

Fuente: Elaboración propia

Shaco		Zilean		Alistar		Shen		Illaoi	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
0.150	0.110	0.600	0.373	0.358	0.319	3.987	3.880	0.627	0.601

Tabla 5.9: ECM y EAM obtenidos con el modelo K -NN Recursivo para el *banrate*

Media aritmética

Cuando se combinan estadísticas utilizando este método, se enfrentan a los mismos problemas que los estadísticos no robustos cuando se encuentran con valores atípicos. Como resultado, las predicciones que están muy alejadas de los valores reales tendrán más influencia que las que no lo están. Esto puede afectar la precisión de la predicción de la combinación y disminuir su fiabilidad.

La media aritmética se define como:

$$\hat{y}_t = \frac{\sum_{i=1}^{\#modelos} \frac{(i)}{t}}{\#modelos} \quad (5.5)$$

donde $\#modelos$ representa el número de modelos utilizados.

Shaco		Zilean		Alistar		Shen		Illaoi	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
0.230	0.188	0.172	0.130	1.520	1.147	4.846	4.796	0.419	0.369

Tabla 5.10: ECM y EAM obtenidos con el modelo K -NN MIMO para el *banrate*

Regresión lineal restringida

Este método implica ajustar un hiperplano de regresión a través de mínimos cuadrados utilizando los valores de las predicciones de los modelos, $\hat{y}_t^{(i)}$, como variables independientes y los valores de los conjuntos de prueba, y_t , como variable dependiente. Se impone la restricción de que los pesos, $\omega^{(i)}$, sean positivos y sumen 1.

Una vez que se ha ajustado el modelo de regresión, se utiliza la siguiente fórmula para realizar la predicción:

$$\hat{y}_t = \omega^{(0)} \sum_{c=1}^{\#modelos} \omega_t^{(i)(i)} \quad (5.6)$$

$$con \omega^{(i)} \geq 0 \text{ y } \sum_{c=1}^{\#modelos} \omega^{(i)} = 1$$

Aunque este modelo es más costoso computacionalmente, es capaz de generar predicciones precisas, especialmente cuando las predicciones individuales están altamente correlacionadas. Además, los pesos que se imponen en este modelo pueden ser interpretados como los porcentajes que cada predicción individual contribuye a la predicción combinada. En contraste, el modelo que solo utiliza una recta de regresión no tiene una interpretación tan directa.

Aplicación al conjunto de datos del *winrate*

La figura 5.14 refleja las predicciones modelo de combinación por la media aritmética fuera de los entrenamientos, y se comprueba que *Jayce* obtiene valores por encima de los reales. Los datos de *Malphite* y *Morgana* están por debajo y se observa que la tendencia varía cuando más se avanza en el tiempo. *Taliyah* tiene tendencias similares siempre por encima de los datos reales y los datos de *Rek'Sai* son bastante constantes. La tabla 5.11 refleja los errores obtenidos.

La figura 5.15 refleja las predicciones del modelo de combinación por la Regresión lineal restringida fuera de los entrenamientos, y se comprueba que para




Figura 5.14: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de combinación por la media aritmética, azul y los datos de prueba, morado, para el *winrate*

Fuente: Elaboración propia

Jayce		Rek'Sai		Taliyah		Malphite		Morgana	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
0.877	0.625	0.776	0.733	0.649	0.449	1.441	1.111	0.785	0.688

Tabla 5.11: ECM y EAM obtenidos con el modelo combinación por Media Aritmética para el *winrate*

los cinco grupos se obtienen valores bastante similares a los reales. El caso de *Malphite* es el que ofrece peores resultados, aunque estos son mejores que todos los anteriores. La tabla 5.12 refleja los errores obtenidos.

Aplicación al conjunto de datos del *banrate*

La figura 5.16 refleja las predicciones para el modelo recursivo fuera de los entrenamientos, y se comprueba que *Illaoi*, *Zilean*, *Alistar* y *Shaco* tienen valores y tendencias demasiados cercanos a la realidad pero *Shen* sigue con datos bastante lejanos. La tabla 5.13 refleja los errores obtenidos.

La figura 5.17 refleja las predicciones para el modelo recursivo fuera de los entrenamientos, y se comprueba que *Illaoi*, *Zilean*, *Alistar* y *Shaco* tienen valores




Figura 5.15: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de combinación por la Regresión lineal restringida, azul y los datos de prueba, morado, para el *winrate*

Fuente: Elaboración propia




Figura 5.16: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de combinación por la media aritmética, azul y los datos de prueba, morado, para el *banrate*

Fuente: Elaboración propia

Jayce		Rek'Sai		Taliyah		Malphite		Morgana	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
0.738	0.489	0.614	0.461	0.521	0.413	0.860	0.713	0.350	0.289

Tabla 5.12: ECM y EAM obtenidos con el modelo combinación por Regresión lineal restringida para el *winrate*

Shaco		Zilean		Alistar		Shen		Illaoi	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
0.588	0.468	0.247	0.203	1.861	1.629	4.253	4.176	0.507	0.462

Tabla 5.13: ECM y EAM obtenidos con el modelo combinación por Media Aritmética para el *banrate*

y tendencias demasiados cercanos a la realidad y *Shen* sigue con valores bastante dispares, pero son mejores que los anteriores. La tabla 5.14 refleja los errores obtenidos.




Figura 5.17: Comparación de el conjunto de datos de entrenamiento, verde, las predicciones por el modelo de combinación por la Regresión lineal restringida, azul y los datos de prueba, morado, para el *banrate*

Fuente: Elaboración propia

Shaco		Zilean		Alistar		Shen		Illaoi	
ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
0.147	0.109	0.139	0.111	0.068	0.057	2.204	1.991	0.289	0.257

Tabla 5.14: ECM y EAM obtenidos con el modelo combinación por Regresión lineal restringida para el *banrate*

6

Resultados

En este capítulo se valora cual es el mejor modelo para cada conjunto de datos. Una vez seleccionado el modelo para cada grupo, cada personaje debe utilizar el modelo asociado a su grupo.

6.1. Resultados del conjunto de *winrate*

Después de registrar todos los errores en la tabla 6.1 y de reunir todas las predicciones en la figura , se observa que el último modelo es el mejor para todos los representantes. Se puede notar que este modelo predice con el mismo error que el modelo *K-NN Recursive* para *Malphite* y *Taliyah*. Por lo tanto, el modelo que mejor se adapta al conjunto de datos de *winrate* es la combinación de los modelos anteriores por media regresiva. El conjunto de *Malphite* el que presenta peores resultados, mientras que el conjunto de *Morgana* es el que ofrece mejores resultados. En resumen, la combinación de modelos permite mejorar las predicciones y obtener mejores resultados en la predicción del *winrate* de los campeones en el juego.

6.2. Resultados del conjunto de *banrate*

Después de recopilar todos los errores en la tabla 6.2 y de reunir todas las predicciones en la figura , se concluye que el mejor modelo para todos los re-




Figura 6.1: Comparación de todos los modelos para el *winrate*
Fuente: Elaboración propia




Figura 6.2: Comparación de todos los modelos para el *banrate*
Fuente: Elaboración propia

6.2. Resultados del conjunto de *banrate*

	Jayce		Rek'Sai		Taliyah		Malphite		Morgana	
Errores	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
<i>SARIMA</i>	0.916	0.849	0.720	0.667	1.007	0.837	1.057	0.718	0.355	0.316
<i>TBATS</i>	0.996	0.908	0.618	0.493	0.760	0.554	1.921	1.607	1.452	1.376
<i>ARNN</i>	1.489	0.941	1.123	0.924	0.733	0.618	2.630	2.193	1.293	1.378
<i>K-NN Rec.</i>	0.898	0.776	1.313	1.224	0.521	0.413	0.860	0.713	0.480	0.401
<i>K-NN MIMO</i>	0.785	0.519	1.364	1.279	0.778	0.678	1.137	0.840	0.740	0.633
Media Arit.	0.877	0.625	0.776	0.733	0.649	0.449	1.441	1.111	0.785	0.688
Media Regr.	0.738	0.489	0.614	0.461	0.521	0.413	0.860	0.713	0.350	0.289

Tabla 6.1: Tabla conjunta de todos los ECM y EAM para el *winrate* por modelo y grupo

	Shaco		Zilean		Alistar		Shen		Illaoi	
Errores	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM	ECM	EAM
<i>SARIMA</i>	1.574	1.448	0.543	0.518	2.757	2.582	2.204	1.991	0.289	0.257
<i>TBATS</i>	0.706	0.682	0.232	0.197	0.480	0.433	3.667	3.586	0.304	0.273
<i>ARNN</i>	2.900	2.080	0.533	0.488	6.618	5.674	6.699	6.625	1.104	0.886
<i>K-NN Rec.</i>	0.150	0.110	0.600	0.373	0.358	0.319	3.987	3.880	0.627	0.601
<i>K-NN MIMO</i>	0.230	0.188	0.172	0.130	1.520	1.147	4.846	4.796	0.419	0.369
Media Arit.	0.588	0.468	0.247	0.203	1.861	1.629	4.253	4.176	0.507	0.462
Media Regr.	0.147	0.109	0.139	0.111	0.068	0.057	2.204	1.991	0.289	0.257

Tabla 6.2: Tabla conjunta de todos los ECM y EAM para el *banrate* por modelo y grupo

presentantes es el último. Se ha observado que este modelo tiene el mismo error que *SARIMA* para *Illaoi* y *Shen*. Por lo tanto, se llega a la conclusión de que el modelo que mejor se adapta al conjunto de datos de *banrate* es la combinación de los modelos anteriores por media regresiva. Se ha encontrado que el conjunto de *Shen* arrojará los peores resultados y el conjunto de *Alistar* será el que tendrá mejores resultados. Esto sugiere que el modelo puede ser muy útil para predecir el *banrate* de diferentes representantes en el futuro.

7

Conclusiones

Este apartado alude al cumplimiento de los objetivos propuestos.

En conclusión, en este trabajo se han alcanzado todos los objetivos que se propusieron al principio de la investigación. En primer lugar, se ha encontrado que la combinación de modelos por media regresiva es la que mejor se adapta a todas las series de datos. Además, se ha recopilado y procesado toda la información temporal de los campeones y versiones disponibles para su posterior análisis. Se han clasificado los datos en grupos representados por un candidato y se han generado predicciones para el futuro a partir de los modelos creados. Finalmente, se han comparado los resultados obtenidos con la realidad, lo que nos permite validar la calidad de los modelos y su utilidad para la toma de decisiones en diferentes áreas de aplicación. En resumen, el presente trabajo constituye una herramienta útil para la gestión y análisis de datos temporales complejos, y demuestra la importancia del uso de modelos estadísticos y de aprendizaje automático para la predicción y toma de decisiones precisas en diferentes campos de estudio.

8

Mejoras y trabajos futuros

Este capítulo está dedicado a la ultima parte de los objetivos centrada en la mejora del estudio.

Para mejorar el estudio, se puedes incluir otros modelos de predicción, como las máquinas de vector soporte o otro tipo de combinación de modelos, como la combinación de media ponderada con pesos según el ECM. La inclusión de nuevos modelos podrian mejorar o debilitar las predicciones y sus combinaciones.

Por otro lado, para mejorar el estudio de estas series con futuro a crear una aplicación que se pudiese utilizar con fines estratégicos, se sugiere que al tener varias estadísticas disponibles en el tiempo, se utilicen modelos de predicción con más variables, como juntar las dos variables estudiadas en este proyecto o incluir otras como la popularidad del campeón, su rol, su posición en el mapa o otra de las múltiples estadísticas que se pueden extraer de este juego.

Bibliografía

- [1] N. Gamer, “League of legends fue el esport más visto de 2021,” *Marca*, 2022. [Online]. Available: <https://www.marca.com/claro-mx/esports/2022/02/02/61fabfda268e3eb5078b45e3.html>
- [2] A. Rodriguez, “¿qué es el meta-game? diccionario xataka esports,” 2016. [Online]. Available: <https://esports.xataka.com/guias-para-principiantes/diccionario-xataka-esports-meta-game>
- [3] J. Grubb, “Riot turns league of legends data over to the community with new api,” *Venture Beat*, 2013. [Online]. Available: <https://venturebeat.com/2022/01/27/why-traditional-advertising-needs-to-be-kicked-to-the-curb-in-web3>
- [4] M. Martí, “Qué es el web scraping? introducción y herramientas,” 2016. [Online]. Available: <https://web.archive.org/web/20170729001446/https://sitelabs.es/web-scraping-introduccion-y-herramientas>
- [5] M. Martín, “Análisis y modelado de los datos de la verisión 12.7 del videojuego *League of Legends*,” Ph.D. dissertation, Universidad Rey Juan Carlos, 2022.
- [6] “Season seven,” 2017. [Online]. Available: https://leagueoflegends.fandom.com/wiki/Season_Seven
- [7] P. Montero and J. A. Vilar, “Tslust: An r package for time series clustering,” *Journal of Statistical Software*, pp. 1–43, 2014.
- [8] G. C. R. y. G. M. L. G. E. P. Box, G. M. Jenkins, *Time series analysis: forecasting and control*, 4th ed. 500 Sansome St. San Francisco, CAUnited States: Holden-Day, 2016.
- [9] D. Peña, *Análisis de series temporales*, 1st ed. Calle Valentin Beato, 21, Madrid, 28037, Madrid: Alianza Editorial, 2005.
- [10] F. C. y. A. J. R. F. Martínez, M. P. Frias, “Time series forecasting with knn in r: the tsfknn package,” *The R Journal*, vol. 11, pp. 229–242, 2019.